Adversarial Attack on Neural Networks

1. Experimental Setup

MNIST에는 직접 구현한 간단한 CNN(Conv2d 2개 + FC)을 사용했으며, clean accuracy 99.14%를 달성했다. CIFAR-10에는 torchvision의 pretrained EfficientNet_B0을 fine-tuning하여 사용했고, clean accuracy 90.69%를 기록했다 (출처: https://pytorch.org/vision/stable/models/efficientnet.html). EfficientNet_B0을 선택한 이유는 ResNet18(11.7M) 대비 절반 수준의 파라미터(5.3M)로 동등 이상의 성능을 달성하는 효율적인 모델이기 때문이다.

4가지 공격(FGSM Targeted/Untargeted, PGD Targeted/Untargeted)을 각각 eps = {0.05, 0.1, 0.2, 0.3}에 대해 200개 샘플로 평가했다. PGD 하이퍼파라미터는 MNIST의 경우 k=40, eps_step=0.01, CIFAR-10의 경우 k=20, eps_step=0.005를 사용했다.

2. Results

Table 1. MNIST Attack Success Rate (%)

Attack	eps=0.05	eps=0.1	eps=0.2	eps=0.3
FGSM Targeted	0.0%	1.0%	17.5%	51.5%
FGSM Untargeted	2.5%	11.0%	63.5%	92.0%
PGD Targeted	0.0%	4.0%	78.0%	100.0%
PGD Untargeted	3.0%	26.5%	99.0%	100.0%

Table 2. CIFAR-10 Attack Success Rate (%)

Attack	eps=0.05	eps=0.1	eps=0.2	eps=0.3
FGSM Targeted	10.0%	7.0%	8.0%	10.0%
FGSM Untargeted	87.5%	89.0%	91.0%	88.0%
PGD Targeted	100.0%	100.0%	100.0%	100.0%
PGD Untargeted	100.0%	100.0%	100.0%	100.0%

3. Discussion

Iterative vs Single-step: 두 데이터셋 모두에서 PGD가 FGSM보다 높은 성공률을 보였다. 특히 MNIST에서 eps=0.2일 때, FGSM Untargeted 63.5%에 비해 PGD Untargeted는 99.0%를 기록했다. 이는 iterative 공격이 매 스텝마다 gradient 방향을 보정하면서 더 효과적인 adversarial example을 찾아낼 수 있기 때문이다.

Targeted vs Untargeted: Untargeted 공격이 Targeted보다 일관되게 높은 성공률을 보였다. Untargeted는 정답에서 벗어나기만 하면 되므로 9개 방향 중 아무 곳이나 도달하면 성공인 반면, Targeted는 10개 클래스 중 정확히 하나의 특정 클래스에 도달해야 하기 때문이다.

CIFAR-10 FGSM Targeted의 낮은 성공률: CIFAR-10에서 FGSM Targeted의 성공률은 eps를 올려도 7~10% 수준에 머물렀다. 이는 예상과 다른 결과였다. EfficientNet_B0의 decision boundary가 복잡하기 때문에 single-step gradient로 특정 클래스에 정확히 도달하기 어렵고, eps가 커질수록 [0,1] clamp에서 잘려나가는 양이 늘어 실질적 효과가 상쇄된다. 반면 PGD Targeted는 반복으로 방향을 보정하며 100% 성공률을 달성했다. 아래 Figure 1에서 eps=0.05에서도 섭동이 크게 나타나지만 공격은 실패하는 모습을 확인할 수 있다.

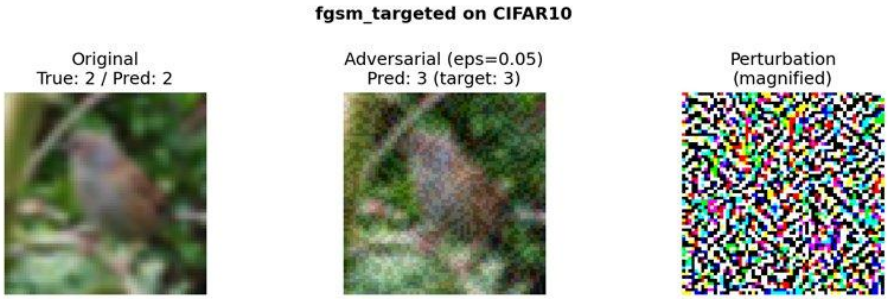

Figure 1. CIFAR-10 FGSM Targeted (eps=0.05) - 섭동에도 불구하고 targeted 공격 실패

EfficientNet의 효율성과 견고성: CIFAR-10에서 PGD는 eps=0.05에서 이미 100% 공격 성공률을 기록했다. eps=0.05의 섭동은 사람 눈에 거의 식별할 수 없는 수준임에도 모델은 완전히 속았다. 이는 EfficientNet_B0이 높은 clean accuracy(90.69%)를 달성했음에도 adversarial robustness와는 무관함을 보여준다. 신뢰할 수 있는 AI 시스템을 위해서는 adversarial training 등의 추가적인 방어 기법이 필요하다.

Epsilon과 가시성의 Trade-off: MNIST에서는 eps가 커질수록 성공률이 점진적으로 상승하는 전형적인 패턴이 관찰되었다. 반면 CIFAR-10에서는 eps=0.05만으로도 PGD가 포화 상태에 이르렀다. 이는 CIFAR-10의 입력 차원(3x64x64=12,288)이 MNIST(1x28x28=784)보다 훨씬 크기 때문에, adversarial perturbation이 활용할 수 있는 방향이 많아 적은 eps로도 효과적인 공격이 가능한 것으로 해석된다. 아래 Figure 2에서 eps=0.05에서도 untargeted 공격이 성공하는 것을 확인할 수 있다.

Figure 2. CIFAR-10 FGSM Untargeted (eps=0.05) - 작은 섭동으로도 오분류 유도 성공