Adversarial Attack on Neural Networks

Analysis Report

1. Experimental Setup

MNIST 에는 직접 구현한 간단한 CNN(Conv2d 2 개 + FC)을 사용했으며, clean accuracy 99.14%를 달성했다. CIFAR-10 에는 torchvision 의 pretrained EfficientNet_B0 을 fine-tuning 하여 사용했고, clean accuracy 90.69%를 기록했다 (출처: https://pytorch.org/vision/stable/models/efficientnet.html). EfficientNet_B0 을 선택한 이유는 ResNet18(11.7M) 대비 절반 수준의 파라미터(5.3M)로 동등 이상의 성능을 달성하는 효율적인 모델이기 때문이다.

4 가지 공격(FGSM Targeted/Untargeted, PGD Targeted/Untargeted)을 각각 eps = {0.05, 0.1, 0.2, 0.3}에 대해 200 개 샘플로 평가했다. PGD 하이퍼파라미터는 MNIST 의 경우 k=40, eps_step=0.01, CIFAR-10 의 경우 k=20, eps_step=0.005 를 사용했다.

2. Results

Table 1. MNIST Attack Success Rate (%)

Attack	eps=0.05	eps=0.1	eps=0.2	eps=0.3
FGSM Targeted	0.0%	1.0%	17.5%	51.5%
FGSM Untargeted	2.5%	11.0%	63.5%	92.0%
PGD Targeted	0.0%	4.0%	78.0%	100.0%
PGD Untargeted	3.0%	26.5%	99.0%	100.0%

Table 2. CIFAR-10 Attack Success Rate (%)

Attack	eps=0.05	eps=0.1	eps=0.2	eps=0.3
FGSM Targeted	10.0%	7.0%	8.0%	10.0%
FGSM Untargeted	87.5%	89.0%	91.0%	88.0%
PGD Targeted	100.0%	100.0%	100.0%	100.0%
PGD Untargeted	100.0%	100.0%	100.0%	100.0%

3. Discussion

Iterative vs Single-step: 두 데이터셋 모두에서 PGD 가 FGSM 보다 높은 성공률을 보였다. 특히 MNIST 에서 eps=0.2 일 때, FGSM Untargeted 63.5%에 비해 PGD Untargeted 는 99.0%를 기록했다. 이는 iterative 공격이 매 스텝마다 gradient 방향을 보정하면서 더 효과적인 adversarial example 을 찾아낼 수 있기 때문이다.

Targeted vs Untargeted: Untargeted 공격이 Targeted 보다 일관되게 높은 성공률을 보였다. Untargeted 는 정답에서 벗어나기만 하면 되므로 9 개 방향 중 아무 곳이나 도달하면 성공인 반면, Targeted 는 10 개 클래스 중 정확히 하나의 특정 클래스에 도달해야 하기 때문이다.

CIFAR-10 FGSM Targeted 의 낮은 성공률: CIFAR-10 에서 FGSM Targeted 의 성공률은 eps 를 올려도 7~10% 수준에 머물렀다. 이는 예상과 다른 결과였다. EfficientNet_B0 의 decision boundary 가 복잡하기 때문에 single-step gradient 로 특정 클래스에 정확히 도달하기 어렵고, eps 가 커질수록 [0,1] clamp 에서

잘려나가는 양이 늘어 실질적 효과가 상쇄된다. 반면 PGD Targeted 는 반복으로 방향을 보정하며 100% 성공률을 달성했다. 아래 Figure 1 에서 eps=0.05 에서도 섭동이 크게 나타나지만 공격은 실패하는 모습을 확인할 수 있다.

Figure 1. CIFAR-10 FGSM Targeted (eps=0.05) - 섭동에도 불구하고 targeted 공격 실패

EfficientNet 의 효율성과 견고성: CIFAR-10 에서 PGD 는 eps=0.05 에서 이미 100% 공격 성공률을 기록했다. eps=0.05 의 섭동은 사람 눈에 거의 식별할 수 없는 수준임에도 모델은 완전히 속았다. 이는 EfficientNet_B0 이 높은 clean accuracy(90.69%)를 달성했음에도 adversarial robustness 와는 무관함을 보여준다. 신뢰할 수 있는 AI 시스템을 위해서는 adversarial training 등의 추가적인 방어 기법이 필요하다.

Epsilon 과 가시성의 Trade-off: MNIST 에서는 eps 가 커질수록 성공률이 점진적으로 상승하는 전형적인 패턴이 관찰되었다. 반면 CIFAR-10 에서는 eps=0.05 만으로도 PGD 가 포화 상태에 이르렀다. 이는 CIFAR-10 의 입력 차원(3x64x64=12,288)이 MNIST(1x28x28=784)보다 훨씬 크기 때문에, adversarial perturbation 이 활용할 수 있는 방향이 많아 적은 eps 로도 효과적인 공격이 가능한 것으로 해석된다. 아래 Figure 2 에서 eps=0.05 에서도 untargeted 공격이 성공하는 것을 확인할 수 있다.

Figure 2. CIFAR-10 FGSM Untargeted (eps=0.05) - 작은 섭동으로도 오분류 유도 성공